APRENDIZAGEM POR REFORÇO

Luís Morgado

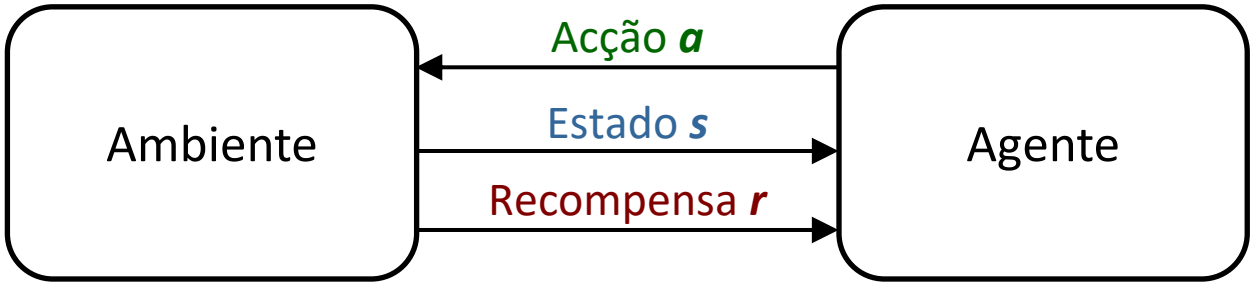
ISEL-DEI

APRENDIZAGEM POR REFORÇO

- **Resolução do problema de decisão sequencial com base na experiência**, de forma iterativa por interacção directa com o ambiente
- **Aprendizagem de comportamentos (*padrões de acção*)**
- Aprendizagem a partir da **interacção** com o ambiente
- Aprendizagem em **continuidade**
  - A aprendizagem ocorre ao longo da operação do agente no ambiente

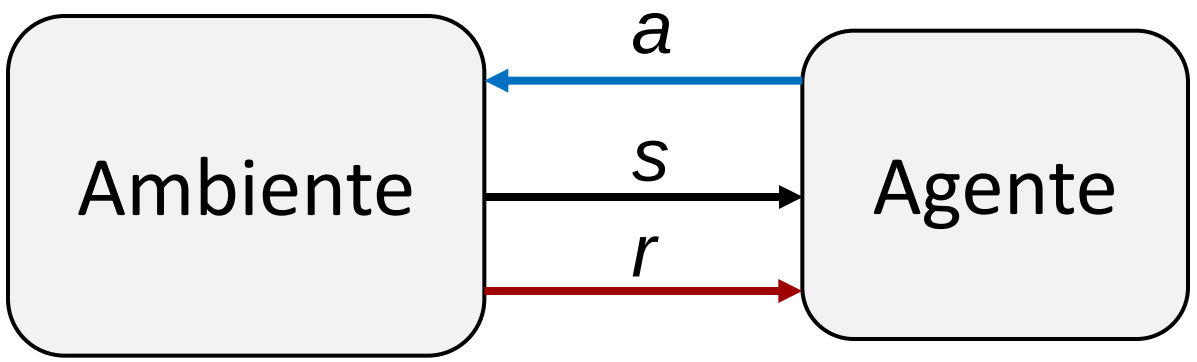
APRENDIZAGEM POR REFORÇO

- **Aprendizagem de comportamentos**
  - Aprender "*como fazer*"
  - Relação entre estados e acções
  - Com base numa medida de desempenho (*recompensa*) obtida por interacção directa com o ambiente
  - **Resolução iterativa de um problema de decisão sequencial através da acção concreta no ambiente**



APRENDIZAGEM POR REFORÇO

- Aprendizagem a partir da **interacção** com o ambiente
  - **Acção** *a*
  - **Estado** *s*
  - **Recompensa** *r* (utilizada como *reforço*)
    - Ganho / perda

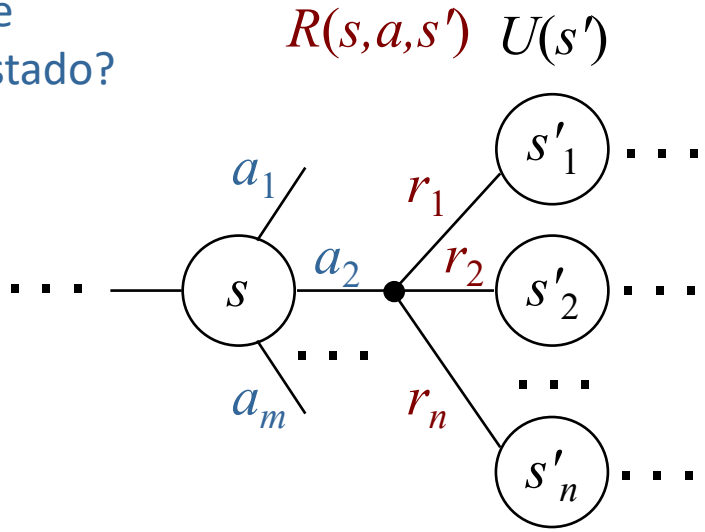


APRENDIZAGEM POR REFORÇO

Qual a acção $\boldsymbol{a}$ que um agente deve realizar num estado $\boldsymbol{s}$?

Qual é a política de acção para cada estado?

$\pi(s) = ?$



Princípio da decisão óptima:

$$\pi^*(s) = \text{argmax}_{a \in A(s)}\, U(s,a)$$

$$U(s,a) = E\langle R(s,a,s') + \gamma U(s') \rangle$$

UTILIDADE DE ACÇÃO COM MODELO

Cálculo da utilidade de acção $U(s,a)$ com base em modelos conhecidos de transição $T(s,a,s')$ e de recompensa $R(s,a,s')$

$$U(s,a) = E\langle R(s,a,s') + \gamma U(s')\rangle \qquad E\langle x\rangle = \sum_{i=0}^{n} p(x_i)x_i$$

$$U(s,a) = \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U(s')]$$

$$\pi^*(s) = \text{argmax}_{a\in A(s)}\, U(s,a)$$

PROCESSOS DE DECISÃO SEQUENCIAL

Problema

- Modelos de transição ***T(s, a, s')*** e de recompensa ***R(s, a, s')*** desconhecidos

$$U^{\pi^*}(s) = \max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U^{\pi}(s')]$$

? ?

ESTIMATIVA DE VALOR DE ACÇÃO

Quando não são conhecidos os modelos de transição $T(s,a,s')$ e de recompensa $R(s,a,s')$, é possível realizar a estimativa de valor de acção $Q(s,a)$ por amostragem

$$U(s,a) = E\langle R(s,a,s') + \gamma U(s')\rangle$$

$$U(s,a) \approx Q(s,a)$$

$$U(s') \approx Q(s',a'),\ \ \pi(s') = a'$$

$$Q(s,a) = E\langle r + \gamma Q(s',a')\rangle$$ Amostra r de $R(s,a,s')$

$$\pi^*(s) \approx \text{argmax}_{a \in A(s)}\, Q(s,a)$$

ESTIMATIVA DE VALOR DE ACÇÃO

Para um conjunto finito de n amostras (s, a, r, s', a') a estimativa de valor $Q(s,a)$ é calculada com base nas amostras observadas

Aprendizagem incremental a partir da experiência

$$\boldsymbol{s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots}$$

$$Q(s,a) = E\langle r + \gamma Q(s',a')\rangle$$

$$E\langle x\rangle = \lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$Q(s,a) = \frac{1}{n}\sum_{i=1}^{n}[r_i + \gamma Q(s',a')]$$

$$E\langle x\rangle \approx \frac{1}{n}\sum_{i=1}^{n} x_i$$

Para um conjunto finito de n amostras

ESTIMATIVA DE VALOR DE ACÇÃO

Forma incremental da estimativa de valor $Q(s,a)$

$$Q_n(s,a) = \frac{1}{n}\sum_{i=1}^{n} J_i$$

$$J_i = r_i + \gamma Q_{n-1}(s',a')$$

$$Q_n(s,a) = \alpha\left(J_n + \sum_{i=1}^{n-1} J_i\right) \qquad \alpha = \frac{1}{n}$$

$$Q_n(s,a) = \alpha\left(J_n + (n-1)\frac{1}{n-1}\sum_{i=1}^{n-1} J_i\right)$$

$$Q_n(s,a) = \alpha\big(J_n + (n-1)Q_{n-1}(s,a)\big)$$

$$Q_n(s,a) = \alpha\big(J_n + nQ_{n-1}(s,a) - Q_{n-1}(s,a)\big)$$

$$Q_n(s,a) = Q_{n-1}(s,a) + \alpha\big(J_n - Q_{n-1}(s,a)\big)$$

$$\boxed{Q_n(s,a) = Q_{n-1}(s,a) + \alpha\big(r_n + \gamma Q_{n-1}(s',a') - Q_{n-1}(s,a)\big)}$$

ESTIMATIVA DE VALOR DE ACÇÃO

Cálculo incremental da estimativa de valor $Q(s,a)$

Estimativa anterior do valor de no estado s realizar uma acção a

Retorno esperado

$$Q_n(s,a) = Q_{n-1}(s,a) + \alpha\left(r_n + \gamma Q_{n-1}(s',a') - Q_{n-1}(s,a)\right)$$

Erro de estimativa

Diferença entre a recompensa observada e a estimativa de valor da acção a

APRENDIZAGEM POR REFORÇO

Processo de aprendizagem por diferença temporal

- Actualização da estimativa de valor de acção com base na mudança desse valor entre instantes sucessivos
  - *Diferença temporal*

Passo de actualização da estimativa de valor $Q(s,a)$:

Nova Estimativa $\leftarrow$ Estimativa + α(Retorno – Estimativa)

$$Q(s,a) \leftarrow Q(s,a) + \alpha\left(r_n + \gamma Q(s',a') - Q(s,a)\right)$$

$\alpha \in$ [0,1] - Factor de aprendizagem

ESTIMATIVA DE VALOR DE ACÇÃO

- **Propriedades**
  - Os valores da função *Q* **convergem** no limite se:
    - Cada par estado-acção (*s,a*) for visitado um número ilimitado de vezes
    - O parâmetro α tender para 0 no limite:

      $\alpha(s,a) \approx 1/n$

      Sendo *n* o número de vezes em que a acção *a* foi seleccionada no estado *s*

ESTIMATIVA DE VALOR DE ACÇÃO

- **Problemas não estacionários**
  - A distribuição de probabilidades muda com o tempo
  - O parâmetro α pode assumir valores diferentes de 1/*n* possibilitando uma ponderação não linear das recompensas ao longo do tempo

$\alpha \in [0,1]$ - Factor de aprendizagem

Determina a relevância das recompensas em função do tempo

$\alpha \rightarrow 0$: Maior relevância das recompensas mais antigas

$\alpha \rightarrow 1$: Maior relevância das recompensas mais recentes

EXPLORAÇÃO vs. APROVEITAMENTO

- Duas vertentes da aprendizagem:
  - **Exploração**
    - Escolher uma acção que permita explorar o mundo para melhorar a aprendizagem
    - Tem por objectivo explorar todos os estados possíveis, tentando todas as acções
    - **Acção exploratória**
      - Obtenção de experiência
  - **Aproveitamento**
    - Escolher a acção que leva à melhor recompensa de acordo com a aprendizagem
    - **Acção sôfrega (*Greedy*)**
      - Utiliza o conhecimento resultante da aprendizagem para obter o máximo de recompensa

EXPLORAÇÃO vs. APROVEITAMENTO

- Estimativas de valor de uma acção a
  - $Q_t(a) \approx Q^*(a)$
- Acção de aproveitamento (*greedy*)
  - $a^*_t = \text{argmax}_a[Q_t(a)]$
- Aproveitamento
  - $a_t = a^*_t$
- Exploração
  - $a_t \neq a^*_t$

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- **Dilema explorar *vs*. aproveitar**
  - **Quando é que se aprendeu o suficiente para começar a aplicar o que se aprendeu?**

- **Estratégia sôfrega (*greedy*)**

$$a_t = a^*_t = \text{argmax}_a \, Q_t(a)$$

- **Estratégia ε-*greedy***

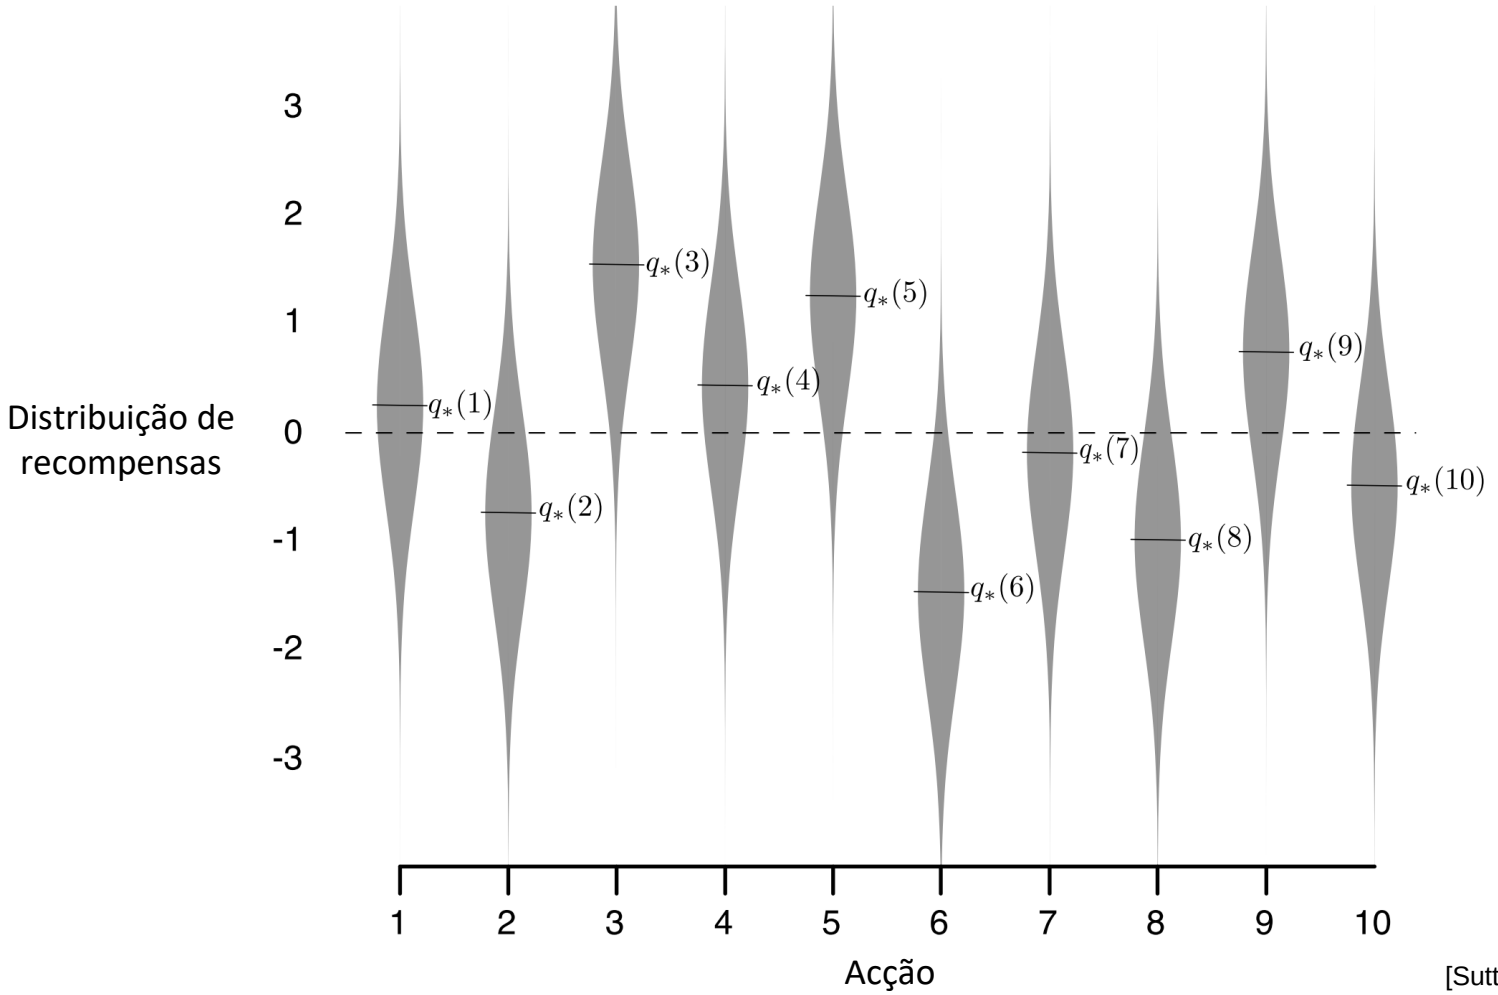
$$a_t = \begin{cases} a^*_t \text{ com probabilidade } 1 - \varepsilon \\ \text{acção aleatória com probabilidade } \varepsilon \end{cases}$$

ε - Probabilidade de exploração

  - **Compromisso entre exploração e aproveitamento**

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Exemplo: Problema de selecção de acção com 10 acções possíveis, $q_*(a)$ indica o valor de cada acção, as recompensas são determinadas com base em distribuições de probabilidade com média $\mu = q_*(a)$ e variância $\sigma^2 = 1$

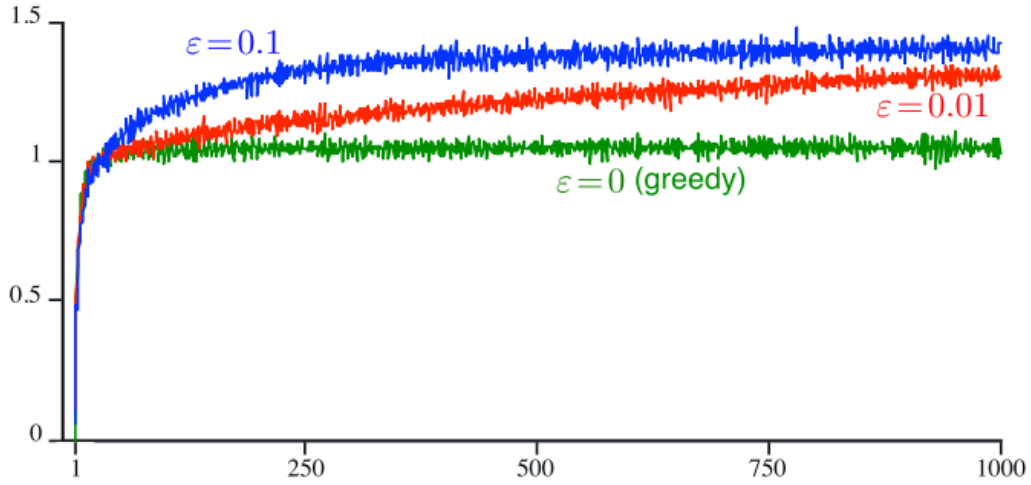


[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

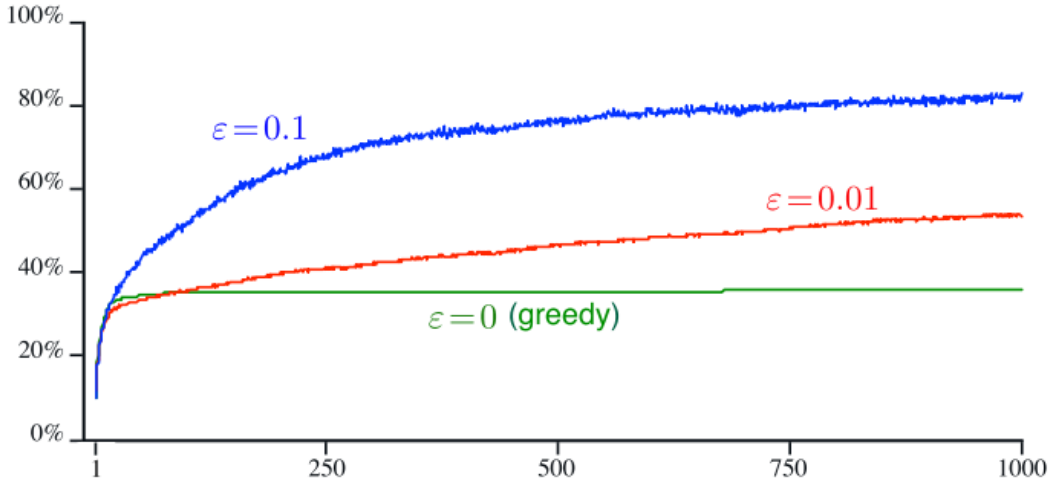
Exemplo:

Recompensa média obtida



Passos

% de escolha da acção óptima



Passos

[Sutton & Barto, 2020]

SELECÇÃO DE ACÇÃO ε-*greedy*

Obter acção sôfrega (*greedy*)

```
1.  accao_sofrega(s):
2.      shuffle(accoes)                    Escolha aleatória entre acções com igual valor
3.      return argmax_{a∈accoes} Q(s, a)
```

Obter acção de exploração

```
1.  accao_exploracao():
2.      return choice(accoes)
```

Seleccionar acção

```
1.  seleccionar_accao(s):
2.      if random() > ε:
3.          accao = accao_sofrega(s)       Aproveitar conhecimento
4.      else:
5.          accao = accao_exploracao()     Explorar
6.      return accao
```

MEMÓRIA DE APRENDIZAGEM

Iniciar memória de aprendizagem

```
1.  iniciar(valor_omissao = 0.0):
2.      this.valor_omissao = valor_omissao
3.      Q = {}                    Memória de aprendizagem Q : (s, a) → ℝ
4.      estados = set()           Estados observados
```

Obter *Q*(*s*, *a*)

```
1.  q(s, a):
2.      return Q.get((s, a), valor_omissao)
```

Actualizar memória de aprendizagem

```
1.  actualizar(s, a, q):
2.      estados.add(s)
3.      Q[(s, a)] = q
```

Obter estados conhecidos

```
1.  obter_estados():
2.      return estados
```

ALGORITMO *SARSA*

Controlo de aprendizagem com política de selecção de acção única ("*On-Policy*")

- Utilização da mesma política para acção e aprendizagem
- Exploração de todas as acções (por exemplo, estratégia ε-*greedy*)

Passo de aprendizagem:

$$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a'$$

1. No estado s executar a acção a, observar r e s'
2. Escolher a' de acordo com s' com base numa política derivada de Q (por exemplo, ε-*greedy*)
3. Actualizar Q:
   $$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma\, Q(s',a') - Q(s,a)]$$
4. Actualizar $s \leftarrow s'$, $a \leftarrow a'$

APRENDIZAGEM POR REFORÇO *SARSA*

Passo de aprendizagem

```
1. aprender(s, a, r, s′, a′):
2.    Q(s, a) = Q(s, a) + α(r + γQ(s′, a′) − Q(s, a))
```

ALGORITMO *SARSA*

Aprendizagem incremental a partir da experiência:

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$

1. Iniciar $Q(s,a)$
2. Repetir (por cada episódio)
3. Iniciar s
4. Escolher a de acordo com s com base numa política derivada de Q (por exemplo, ε-*greedy*)
5. Repetir (por cada passo)
6. Executar acção a, observar r e s'
7. Escolher a' de acordo com s' com base numa política derivada de Q (por exemplo, ε-*greedy*)
8. aprender(s, a, r, s', a')
9. Actualizar $s \leftarrow s'$, $a \leftarrow a'$
10. Até s ser um estado terminal

RETORNO DE ESTADOS TERMINAIS

Nos estados terminais, correspondentes ao final de um episódio, não existem acções seguintes a realizar

Passo de experiência com continuidade

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$ Continuação de episódio

$J(s,a) = r + \gamma Q(s',a')$ Retorno $J(s,a)$ depende de recompensas futuras

Passo de experiência final

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow \square$ Fim de episódio, s' é um estado terminal

$J(s,a) = r$ Retorno $J(s,a)$ só depende de recompensa observada

REFERÊNCIAS

[Sutton & Barto, 2020]

R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]

D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]

C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003

[Koppula, 2020]

R. Koppula, “Exploration vs. Exploitation In Reinforcement Learning”, *https://www.manifold.ai/exploration-vs-exploitation-in-reinforcement-learning*, 2020