APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEI

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- Na estratégia de **selecção de acção ε-*greedy*** o valor de ε determina um **compromisso fixo** entre exploração e aproveitamento
  - **Mesmo depois de muita exploração** e consequente obtenção de conhecimento, **a probabilidade de exploração mantém-se fixa**
- No entanto, **à medida que o agente obtém mais conhecimento, a probabilidade de exploração pode baixar**
  - Permite aproveitar o conhecimento obtido
  - Evita perdas por exploração desnecessária

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- **Inicialmente o agente tem pouco conhecimento** sobre o ambiente
  - **O valor de ε deve ser elevado** para que o agente possa explorar e obter conhecimento sobre o ambiente
- **Quando o agente obtém mais conhecimento** sobre o ambiente
  - **O valor de ε deve diminuir** para que possa aproveitar esse conhecimento
    - Seleccionando acções com maior valor estimado $Q(a)$

ESTRATÉGIA DE SELECÇÃO ε-*greedy*

Limitações:

- **Exploração excessiva ou insuficiente**
  - O valor da taxa de exploração **ε** deve ser adequadamente definido
    - **Um valor muito alto** pode levar a uma **exploração excessiva**, resultando num processo de **aprendizagem ineficiente**
    - **Um valor muito baixo** pode levar a uma **exploração insuficiente**, resultando na **aprendizagem de uma política sub-óptima**
- **Decaimento da taxa de exploração ε**
  - Possibilita melhorar o desempenho ao longo do tempo
    - O valor de **ε** diminui à medida que o agente aprende
  - **Requer a escolha da taxa de decaimento**
    - Se não for adequada pode levar a um desempenho sub-óptimo

ESTRATÉGIA DE SELECÇÃO ε-*greedy*

Limitações:

- **Convergência lenta**
  - Em ambientes onde **as recompensas são esparsas ou onde há muitas acções possíveis**, a estratégia ε-*greedy* pode levar a uma convergência lenta, devido à **exploração de acções que não são informativas**
- **Não considera a incerteza**
  - A estratégia ε-*greedy* não tem em conta a incerteza nas estimativas de valor das acções
    - **Todas as acções são consideradas com igual probabilidade de exploração**
      - Esta estratégia pode não ser adequada em situações onde algumas acções têm maior incerteza do que outras

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Para realizar a **adaptação dinâmica do compromisso entre exploração e aproveitamento** ao longo do processo de aprendizagem, é necessária a **variação do valor de ε ao longo do tempo**

- Estratégia de selecção de acção ***ε-greedy com decaimento***
  - O valor de ε varia ao longo do tempo de acordo com uma determinada estratégia de variação
    - Decaimento linear com o tempo
    - Decaimento não-linear com o tempo
    - Decaimento dependente de recompensas

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- **Estratégia ε-*greedy* com decaimento**

$$a_t = \begin{cases} a^*_t \text{ com probabilidade } 1 - \varepsilon_t \\ \text{acção aleatória com probabilidade } \varepsilon_t \end{cases}$$

ε_t - Probabilidade de exploração variável com o tempo

Diversas estratégias de variação de ε_t

- Decaimento linear com o tempo
- Decaimento não-linear com o tempo
- Decaimento dependente de recompensas

ESTRATÉGIA DE SELECÇÃO DE ACÇÃO

Método de selecção da acção a realizar em cada estado de modo a garantir um compromisso entre exploração e aproveitamento

- **Estratégia ε-*greedy***
  - **Compromisso fixo** entre exploração e aproveitamento
    - Probabilidade de exploração ε é fixa
- **Estratégia ε-*greedy com decaimento***
  - **Compromisso variável** entre exploração e aproveitamento
    - O valor de ε varia ao longo do tempo de acordo com uma determinada estratégia de variação
      - Por exemplo, decaimento linear com o tempo

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

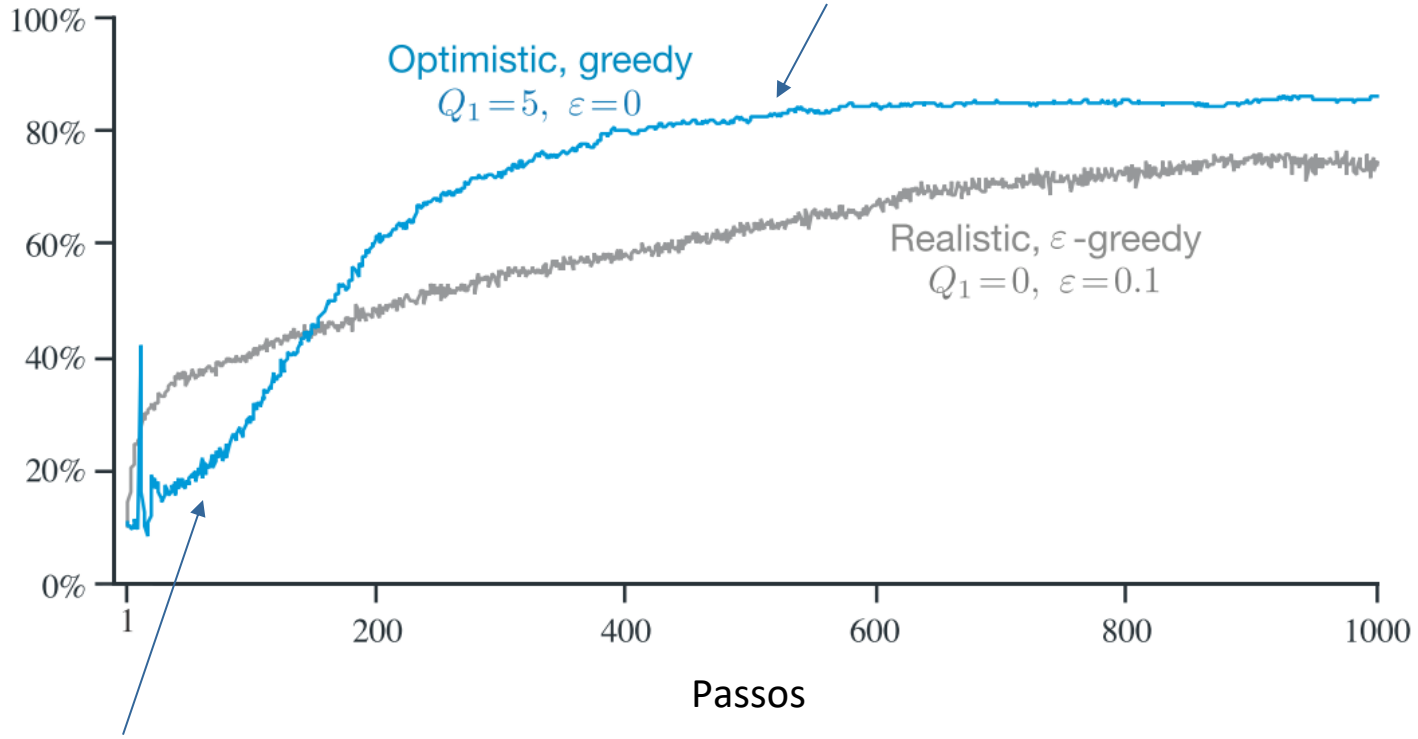
Selecção de acção com valores iniciais optimistas

- **Tem por objectivo promover a exploração**
  - Ao atribuir valores iniciais optimistas às acções (valores maiores que os reais), é promovida a exploração dessas acções, possibilitando a observação do seu valor efectivo
- **À medida que o agente interage com o ambiente, os valores das acções são actualizados com base nas recompensas reais obtidas**
  - Os valores das acções são ajustados para reflectirem as recompensas reais, no sentido da convergência progressiva para uma política óptima

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com valores iniciais optimistas

- Exemplo:



[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com valores iniciais optimistas

- **Vantagens**:
  - **Promove a exploração**
    - Promove a exploração inicial do conjunto de acções possíveis, o que é importante em ambientes complexos
  - **Reduz o risco de convergência prematura**
    - Contribui para evitar que ocorra uma convergência prematura para acções sub-óptimas, levando a uma melhoria da qualidade da política aprendida

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com valores iniciais optimistas

- **Desvantagens**:
  - **Custo computacional**
    - A exploração excessiva pode levar a um custo computacional elevado, em particular em ambientes de grandes dimensões ou complexos
  - **Dependência de valores iniciais**
    - A eficácia desta estratégia de selecção de acção é dependente da escolha dos valores iniciais
      - Devem ser suficientemente optimistas
      - No entanto, não devem ser excessivamente elevados de modo a distorcer a aprendizagem

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com limites de confiança *Upper Confidence Bounds* (UCB)

- Considera a incerteza associada a cada acção
- Para cada acção é mantida a seguinte informação:
  - **Estimativa de valor**
  - **Medida de incerteza do valor da acção**
- O critério de selecção de acção tem em conta a estimativa de valor da acção e um **termo de confiança** que **reflecte a incerteza** acerca do valor da acção

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com limites de confiança *Upper Confidence Bounds* (UCB)

- **Termo de confiança**
  - Medida de incerteza acerca do valor da acção
  - Maior para acções menos exploradas
    - **Maior incerteza de valor**
  - Reduz-se quando uma acção é mais explorada e de forma relativa ao longo do tempo

$$Conf(a) = c\sqrt{\frac{\ln t}{N_t(a)}}$$

c - Factor de confiança

t - Instante de tempo (número de passos de acção realizados)

$N_t(a)$ - Número de vezes que a acção *a* foi realizada

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com limites de confiança *Upper Confidence Bounds* (UCB)

- Critério de selecção de acção
  - O termo de confiança acresce ao valor da acção definindo um **limite superior do valor da acção**
    - Expressa uma margem de incerteza acerca do valor da acção
    - Acções com maior incerteza de valor devem ser mais exploradas

$$a_t = argmax_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

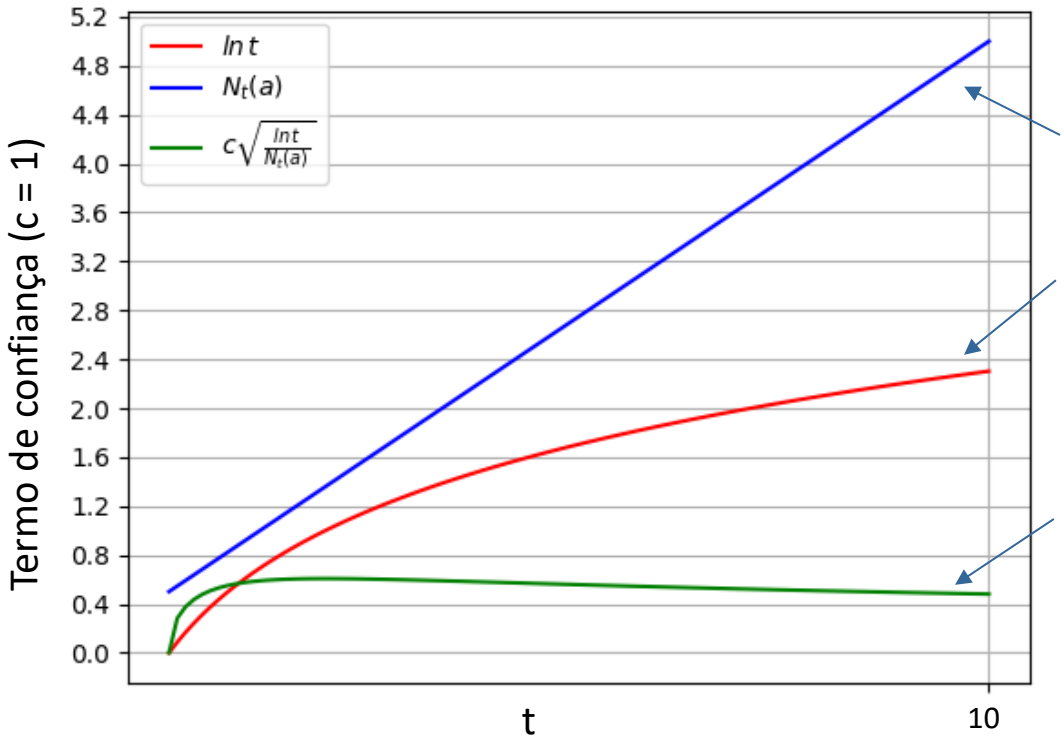
a_t - Acção seleccionada no instante *t*

$Q_t(a)$ - Estimativa de valor da acção *a*

EFEITO DO TERMO DE CONFIANÇA

A estratégia de selecção de acção UCB promove a exploração de acções que foram escolhidas menos frequentemente

- O termo de confiança é maior para essas acções
- Mesmo que uma acção tenha um valor estimado menor, pode ser escolhida se não tiver sido realizada muitas vezes



O número de vezes que a acção *a* é realizada cresce linearmente

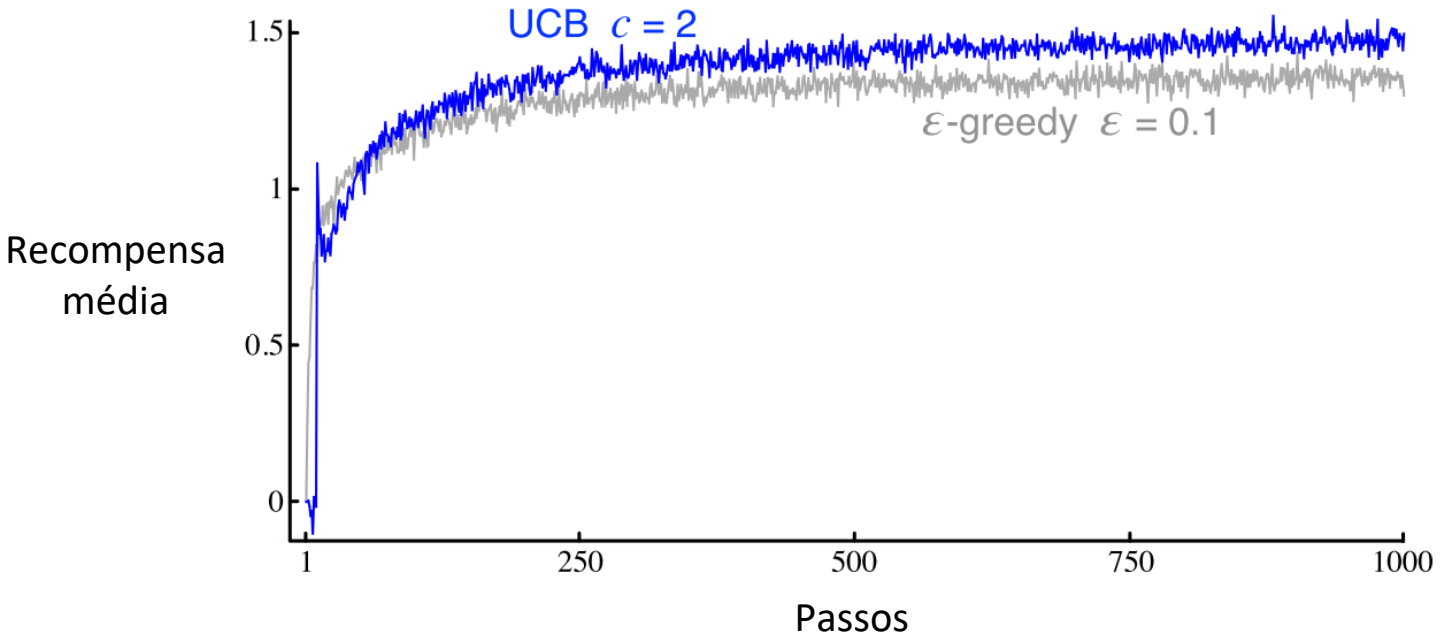
O número de passos temporais *t* cresce logaritmicamente

À medida que a acção é realizada mais vezes e que o tempo passa, o termo de confiança reduz-se, expressando menor incerteza no valor da acção

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com limites de confiança
Upper Confidence Bounds (UCB)

- Exemplo:

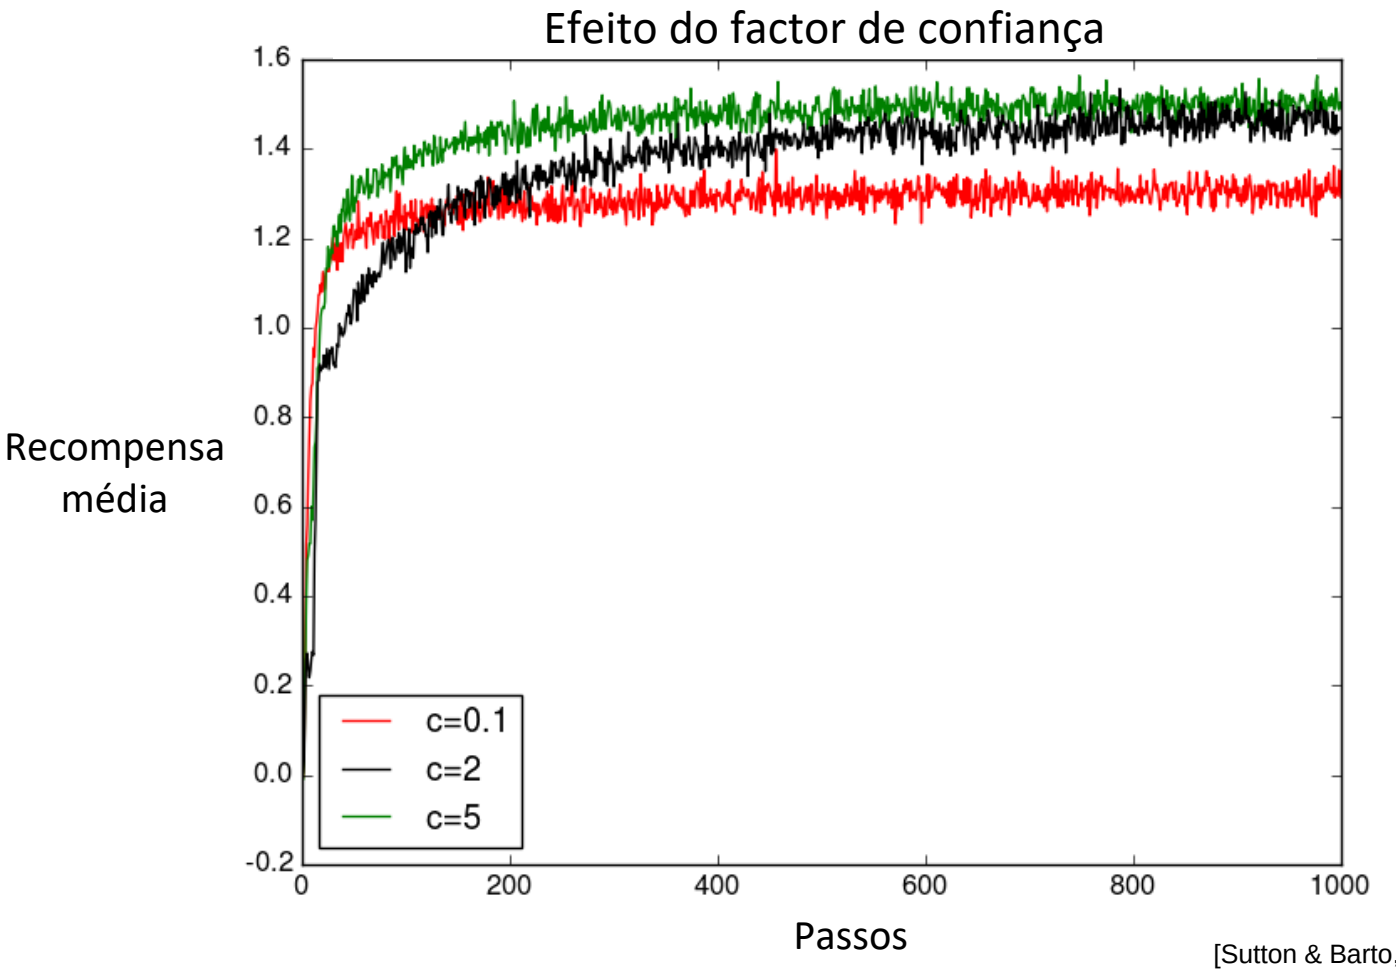


[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção com limites de confiança

Upper Confidence Bounds (UCB)



[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Selecção de acção *Softmax*

- As acções são escolhidas com uma probabilidade que é uma função não linear do seu valor estimado
  - Possibilita a regulação do compromisso entre exploração e aproveitamento com base no valor relativo das acções
- Critério de selecção de acção:

$$P(a) = \frac{e^{Q(a)/T}}{\sum_{a_i} e^{Q(a_i)/T}}$$

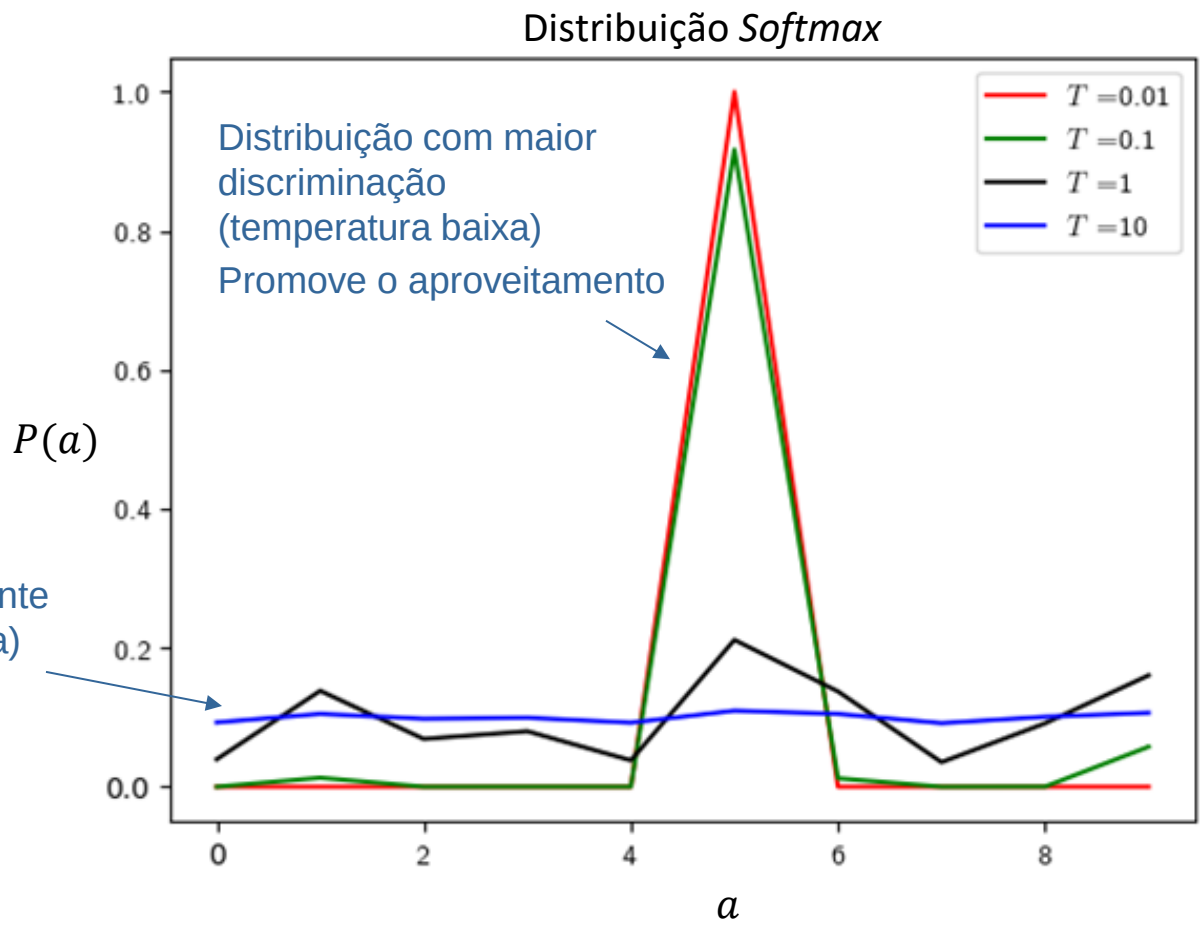
$Q(a)$ – Valor estimado da acção a

$P(a)$ – Probabilidade de selecção da acção a

T – Parâmetro designado *"temperatura"*, determina o grau de exploração

SELECÇÃO DE ACÇÃO SOFTMAX

$$P(a) = \frac{e^{Q(a)/T}}{\sum_{a_i} e^{Q(a_i)/T}}$$



SELECÇÃO DE ACÇÃO SOFTMAX

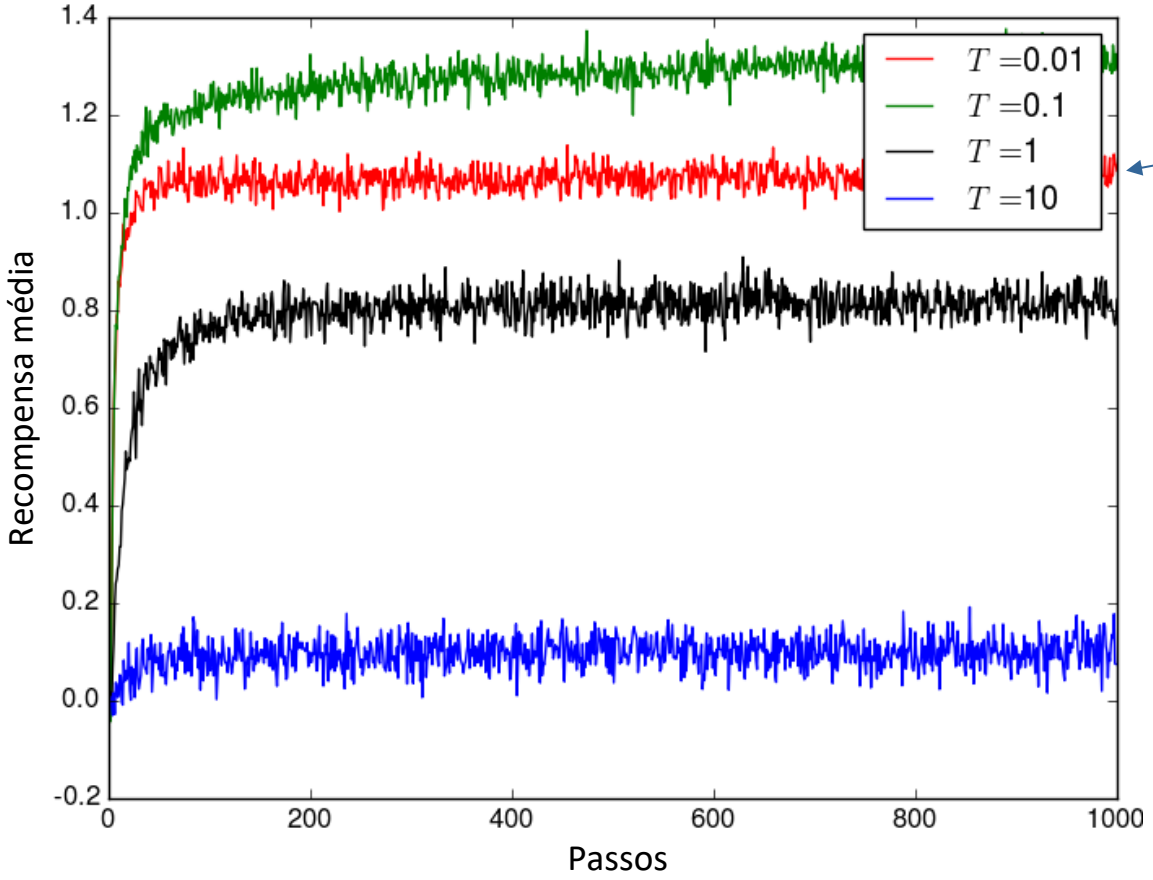
Efeito do parâmetro T (*temperatura*)

- **Temperatura alta**
  - As diferenças entre as estimativas de valor são suavizadas, resultando numa distribuição de probabilidade mais uniforme
  - **Promove a exploração**, pois todas as acções têm uma probabilidade próxima de serem escolhidas
- **Temperatura baixa**
  - A função *Softmax* produz uma maior distinção de probabilidades, favorecendo acções com estimativas de valor mais elevadas
  - **Promove o aproveitamento**, pois as acções com maior estimativa de valor tem maior probabilidade de selecção
  - No limite, quando $T \rightarrow 0$ a selecção de acção torna-se sôfrega (*greedy*)

SELECÇÃO DE ACÇÃO SOFTMAX

Parâmetro T (*temperatura*)

- Pode ter um impacto significativo no desempenho do agente
- Um valor inadequado pode levar a uma exploração insuficiente ou excessiva



Com uma temperatura muito baixa a selecção de acção torna-se tendencialmente sôfrega (*greedy*), com exploração insuficiente, resultando na degradação do desempenho da aprendizagem

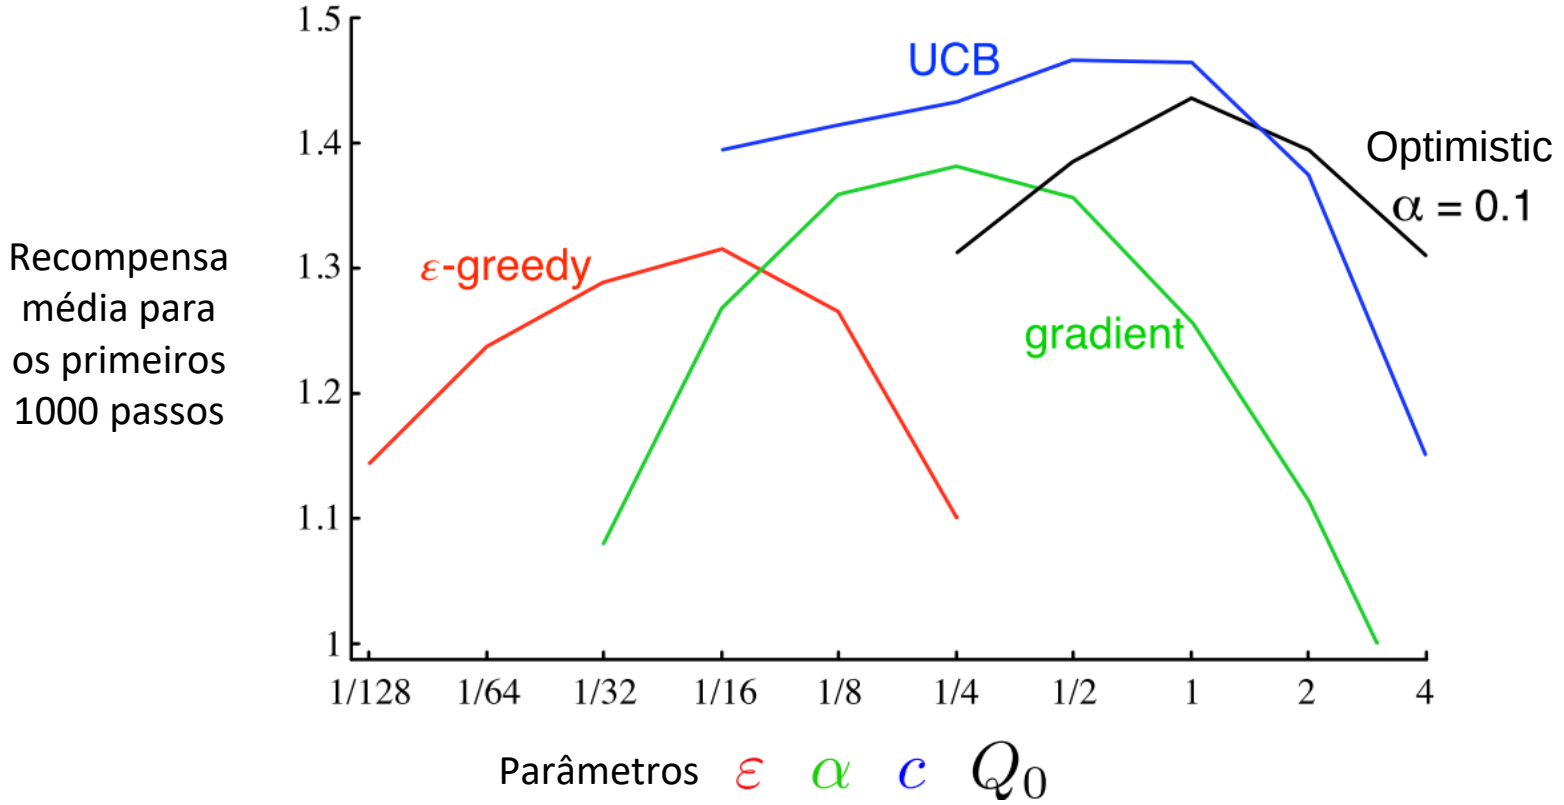
ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- Outras estratégias de selecção de acção
  - **Selecção de acção baseada no gradiente da estimativa de valor**
    - A probabilidade de selecção de uma acção é baseada no gradiente da estimativa de valor
    - Possibilita o ajuste da exploração de forma adaptativa em função das variações nas estimativas de valor
  - **Selecção de acção baseada em heurísticas**
    - A probabilidade de selecção de uma acção é baseada em conhecimento do domínio do problema
    - Possibilita a adequação da exploração em função de características conhecidas do problema a resolver, por exemplo, a distância a um objectivo
    - Pode levar à aprendizagem de políticas sub-óptimas

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Exemplo:

Comparação de diferentes estratégias para o problema de selecção de acção com 10 acções possíveis



Adaptado de [Sutton & Barto, 2020]

O desempenho dos diferentes métodos de selecção de acção varia em função das características do domínio do problema

REFERÊNCIAS

[Sutton & Barto, 2020]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]
D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]
C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003